



TECNOLÓGICO
NACIONAL DE MÉXICO



TECNOLÓGICO NACIONAL DE
MÉXICO CAMPUS CULIACÁN

DISEÑO DE UN MODELO PREDICTIVO BASADO
EN REDES NEURONALES ARTIFICIALES PARA
EL PRONÓSTICO DE CONCENTRACIONES DE
PM2.5

Temas de Inteligencia Artificial

Rodriguez Lopez Said Armando
Santacruz Maldonado Oscar Said

Zuriel Dathan Mora Felix

Ingeniería en Sistemas computacionales
9no Semestre

9:00 - 10:00

18/09/2026

Índice

Índice de Tablas y Figuras	1
Introducción	4
Justificación	5
Alcance	8
Objetivos General y Específicos	9
Objetivo General	9
Objetivos Específicos.....	9
Desarrollo.....	10
1. Dinámica Ambiental y Epidemiológica del PM2.5 en Culiacán	10
2. Marco Normativo de la Calidad del Aire en México.....	12
3. Fundamentación Teórica de las Redes Neuronales Artificiales	13
4. Propuesta de Solución: Sistema Predictivo.....	16
5. Análisis del Impacto Potencial de la Solución.....	21
Agenda	23
Conclusiones	24
Referencias.....	25

Índice de Tablas y Figuras

Tablas

Tabla 1. Límites normativos de PM2.5 y concentraciones observadas en Culiacán	6
Tabla 2. Categorías del Índice aire y salud para PM2.5	13
Tabla 3. Subajuste y sobreajuste: causas, síntomas y soluciones	16
Tabla 4. Variables de entrada consideradas para el entrenamiento del modelo	18
Tabla 5. Cronograma de actividades del proyecto	23

Figuras

Figura 1. Concentración promedio anual de PM2.5 en Culiacán frente a los límites normativos	7
Figura 2. Patrón estacional de PM2.5 en Culiacán: meses invernales frente al mes más limpio del año	11
Figura 3. Diagrama de flujo de las cuatro fases operativas del sistema predictivo propuesto	16
Figura 4. Arquitectura propuesta del perceptrón multicapa para el pronóstico de PM2.5	20

Glosario

Este glosario fija el sentido con el que se emplean los conceptos centrales del trabajo. Reúne los términos de calidad del aire y de aprendizaje automático cuyo significado conviene precisar antes de la lectura; los conceptos propios del modelado se desarrollan con detalle en el apartado correspondiente del desarrollo.

PM2.5. Material particulado fino conformado por partículas sólidas y líquidas suspendidas en el aire cuyo diámetro aerodinámico es igual o menor a 2.5 micrómetros. Su tamaño le permite alcanzar los alvéolos pulmonares y el torrente sanguíneo.

Inversión térmica. Fenómeno meteorológico en el que una capa de aire cálido se ubica por encima de una capa de aire frío cercana al suelo, suprimiendo la convección vertical y confinando los contaminantes en la franja donde respira la población.

Índice aire y salud. Sistema categórico de comunicación del riesgo atmosférico, establecido en la SEMARNAT en el 2023, que traduce las concentraciones de contaminantes a niveles cualitativos con código de color y recomendaciones sanitarias.

Red neuronal artificial (ANN). Modelo computacional inspirado en la organización del sistema nervioso, compuesto por unidades de procesamiento interconectadas que aprenden funciones no lineales a partir de datos históricos.

Serie de tiempo. Secuencia de observaciones ordenadas cronológicamente, en la que cada valor guarda dependencia con los valores que le preceden.

Sensor de bajo costo. Dispositivo de medición de contaminantes basado en dispersión láser, de precio accesible y precisión moderada, empleado en redes ciudadanas de monitoreo hiperlocal.

Perceptrón multicapa (MLP). Arquitectura de red neuronal compuesta por una capa de entrada, una o más capas ocultas y una capa de salida, capaz de aproximar relaciones no lineales complejas.

Función de activación. Transformación no lineal aplicada a la salida de una neurona, como la función sigmoide o la unidad lineal rectificada (ReLU), que otorga a la red la capacidad de representar fenómenos no lineales.

Retropropagación (backpropagation). Algoritmo de entrenamiento que calcula, mediante la regla de la cadena, el gradiente del error respecto de cada peso de la red y lo utiliza para actualizar dichos pesos.

Tasa de aprendizaje. Hiperparámetro que determina la magnitud del ajuste aplicado a los pesos en cada iteración del descenso de gradiente.

Sobreajuste (overfitting). Situación en la que el modelo memoriza el ruido de los datos de entrenamiento y pierde capacidad de generalización ante datos nuevos.

Subajuste (underfitting). Situación en la que el modelo es demasiado simple para capturar la estructura de los datos, presentando un error elevado tanto en entrenamiento como en validación.

Dropout. Técnica de regularización que desactiva aleatoriamente un porcentaje de neuronas durante el entrenamiento para evitar dependencias excesivas entre unidades.

Introducción

La calidad del aire suele deteriorarse sin producir señales visibles inmediatas, aun cuando la expansión urbana y ciertas actividades productivas incrementen la carga de contaminantes. La OMS (2021) relaciona la exposición prolongada a contaminación atmosférica con millones de muertes prematuras cada año. Entre los contaminantes de mayor interés sanitario se encuentran las PM_{2.5}, partículas con diámetro aerodinámico igual o inferior a 2.5 micrómetros. Su tamaño importa. Al ser tan pequeñas, pueden penetrar hasta regiones profundas del pulmón y, en determinados casos, alcanzar el torrente sanguíneo; la evidencia disponible las vincula con efectos respiratorios y cardiovasculares (OMS, 2021).

El problema puede abordarse transformando observaciones ambientales dispersas en datos estructurados para análisis y pronóstico. Esa es la línea que sigue este proyecto. Se plantea diseñar una red neuronal artificial (ANN) capaz de estimar la concentración de PM_{2.5} en Culiacán, Sinaloa, con un horizonte de 24 horas.

Culiacán ofrece un escenario pertinente para evaluar esta propuesta. El tránsito vehicular, la actividad agrícola del valle y episodios meteorológicos como la inversión térmica invernal modifican la acumulación de partículas sobre la zona urbana (Mapasin, 2025). El sistema combinaría registros de sensores ciudadanos de bajo costo con información meteorológica abierta y variables temporales que funcionen como aproximación a la carga vehicular. Con esos insumos se buscaría anticipar periodos de mala calidad del aire y comunicar el pronóstico en un formato útil tanto para la población como para quienes toman decisiones.

Justificación

La pertinencia de un sistema predictivo en Sinaloa se apoya en tres hechos que convergen: la exposición a PM2.5 representa un problema sanitario, el monitoreo oficial ha sufrido interrupciones prolongadas y hoy existen herramientas computacionales capaces de integrar fuentes de información heterogéneas. No se pretende automatizar una lectura disponible en tiempo real. El valor añadido estaría en ganar tiempo horas de anticipación antes de que se presente un episodio desfavorable.

Los estudios disponibles para ciudades de Sinaloa sugieren una carga sanitaria que no puede considerarse menor. En Culiacán y Mazatlán, la exposición sostenida a PM2.5 se ha relacionado con mayor morbilidad y mortalidad por enfermedad pulmonar obstructiva crónica, crisis asmáticas, infecciones respiratorias agudas y padecimientos cardiovasculares. La vulnerabilidad tampoco es uniforme: infantes, mujeres embarazadas y adultos mayores concentran un riesgo mayor durante episodios de contaminación elevada.

A la carga sanitaria se suma un problema de continuidad en la información oficial. Las cuatro estaciones normadas del Gobierno de Sinaloa ubicadas en Culiacán, Mazatlán, Los Mochis y Guasave han permanecido inactivas durante buena parte de la última década por limitaciones de presupuesto, calibración y mantenimiento (El Sol de Sinaloa, s.f.; Revista Espejo, 2024). Sin series oportunas y confiables, dependencias como la Secretaría de Bienestar y Desarrollo Sustentable (SEBIDES) cuentan con menos evidencia para emitir alertas, valorar contingencias o evaluar políticas. Para la población, la consecuencia es sencilla pero relevante: durante periodos prolongados se desconoce con precisión la calidad del aire que se respira.

Las redes ciudadanas han cubierto una parte de ese vacío. Mapasin y Redspira desplegaron sensores hiperlocales de bajo costo en Culiacán, lo que permite seguir el

comportamiento del contaminante fuera de la infraestructura estatal (Redspira, s.f.; Revista Espejo, 2025). Los promedios reportados fueron de $13 \mu\text{g}/\text{m}^3$ en 2024 y $12.69 \mu\text{g}/\text{m}^3$ en 2025 (Mapasin, 2025). Ambos registros superan el límite anual mexicano de $10 \mu\text{g}/\text{m}^3$ y duplican la directriz de $5 \mu\text{g}/\text{m}^3$ recomendada por la OMS (Secretaría de Salud, 2021; OMS, 2021). La Tabla 1 reúne estas referencias, la Figura 1 permite apreciar visualmente la distancia respecto de los umbrales sanitarios.

Referencia o periodo	Concentración anual ($\mu\text{g}/\text{m}^3$)	Promedio de 24 h ($\mu\text{g}/\text{m}^3$)	Situación respecto al límite anual mexicano
Directriz OMS (2021)	5	15	Referencia sanitaria internacional
NOM-025-SSA1-2021 (2024–2025)	10	33	Límite legal vigente en México
NOM-025-SSA1-2021 (desde 2026)	10	25	Endurecimiento del promedio de 24 h
Culiacán, 2024	13.00	No disponible	Excede en 30 % el límite anual
Culiacán, 2025	12.69	No disponible	Excede en 26.9 % el límite anual

Tabla 1. Límites normativos de PM_{2.5} y concentraciones observadas en Culiacán




Figura 1. Concentración promedio anual de PM2.5 en Culiacán frente a los límites normativos

La brecha anterior plantea un reto concreto. Restablecer una red convencional de monitoreo exige equipos, calibración periódica, mantenimiento y personal especializado, un modelo predictivo no reemplaza esos elementos. Sí puede aportar algo distinto: anticipación. Mientras el sensor describe el estado presente, una red entrenada con variables meteorológicas, temporales y de concentración puede estimar el comportamiento probable de las siguientes 24 horas. Ambos componentes son complementarios: la estación normada produce la observación primaria y depende de una operación física continua, mientras que el modelo recibe esas observaciones, incorpora variables exógenas y calcula una estimación futura que puede replicarse en otros sitios siempre que disponga de datos representativos.

Alcance

El proyecto adopta límites deliberados. La delimitación define dónde se estudiará el problema, qué datos alimentarán el modelo y qué tareas permanecerán fuera de esta etapa de trabajo:

- El análisis se limita a la mancha urbana de Culiacán, Sinaloa. En esa zona existen registros históricos procedentes de nodos de la red ciudadana Redspira con continuidad suficiente para plantear un ejercicio de modelado (Redspira, s.f.).
- El pronóstico se mantendrá en un horizonte corto: 24 horas. La salida corresponderá a una serie horaria de PM2.5 para el día siguiente, intervalo compatible con la planeación cotidiana y con medidas preventivas de aplicación inmediata.
- El entrenamiento recurrirá a fuentes abiertas y de dominio público. La Tabla 4 especifica las variables previstas y la función que cada una desempeñará dentro del modelo.
- El componente tecnológico se concentra en ciencia de datos y aprendizaje automático. Incluye el diseño de un perceptrón multicapa, su entrenamiento mediante retropropagación y estrategias de regularización destinadas a controlar el error de generalización. La fabricación de sensores, la instalación de hardware adicional y el desarrollo de una aplicación móvil comercial quedan fuera del alcance actual.
- La predicción numérica se vinculará con la regulación mexicana mediante una etapa posterior de procesamiento. Ese módulo traducirá las concentraciones proyectadas a las categorías y colores del Índice AIRE Y SALUD (Secretaría de Medio Ambiente y Recursos Naturales [SEMARNAT], 2023).

Objetivos General y Específicos

Objetivo General

Diseñar la arquitectura de un modelo predictivo basado en redes neuronales artificiales que estime, con 24 horas de anticipación, las concentraciones horarias de PM2.5 en Culiacán, Sinaloa, a partir de variables meteorológicas y patrones temporales asociados al tráfico, con el propósito de servir como apoyo preventivo ante la disponibilidad limitada de monitoreo ambiental oficial.

Objetivos Específicos

1. Analizar la dinámica local del PM2.5, identificar los factores meteorológicos y antropogénicos relacionados con su acumulación en Culiacán, entre ellos la inversión térmica y el tránsito vehicular, y organizar las fuentes de datos abiertas necesarias para el modelado.
2. Definir la tubería de preprocesamiento, que comprende la limpieza de las series de tiempo, el tratamiento de valores faltantes y el escalamiento de variables, de modo que el conjunto de datos resulte consistente para el entrenamiento de la red neuronal.
3. Especificar la topología de la red neuronal y su estrategia de aprendizaje: capas de entrada, capas ocultas, capa de salida y funciones de activación capaces de representar relaciones atmosféricas no lineales, junto con el entrenamiento por retropropagación del error, los hiperparámetros principales de optimización y las técnicas de regularización destinadas a controlar tanto el sobreajuste como el subajuste.

Desarrollo

El pronóstico de PM2.5 obliga a integrar varias capas del problema. El análisis comienza con el comportamiento físico y estacional del contaminante en Culiacán, continúa con los criterios normativos que convierten una concentración en un nivel de riesgo y, a partir de esa base, define la arquitectura neuronal y el flujo computacional de la propuesta.

1. Dinámica Ambiental y Epidemiológica del PM2.5 en Culiacán

El PM2.5 no corresponde a un gas, sino a una mezcla de partículas sólidas y líquidas suspendidas en el aire. Su diámetro puede ser aproximadamente treinta veces menor que el grosor de un cabello humano (OMS, 2021). En Culiacán, parte de esta carga se asocia con fuentes antropogénicas como la combustión vehicular, la quema de residuos agrícolas en la periferia del valle, ciertas actividades industriales y, durante festividades específicas, la pirotecnia y las fogatas (Mapasin, 2025).

La cantidad emitida explica solo una parte de la concentración que finalmente respira la población. Temperatura, humedad, estabilidad atmosférica y viento pueden dispersar, redistribuir o retener las partículas, los reportes de Mapasin (2025) parecen indicar, además, una estacionalidad clara en Culiacán:

- Invierno, de diciembre a febrero: concentra las condiciones más desfavorables.
Diciembre registra $19.64 \mu\text{g}/\text{m}^3$ en promedio y enero $18.97 \mu\text{g}/\text{m}^3$, valores asociados con jornadas de calidad del aire de regular a mala.
- Verano, de junio a agosto: las concentraciones disminuyen. Agosto presenta un promedio reportado de $7.50 \mu\text{g}/\text{m}^3$; la convección y la precipitación favorecen tanto la dispersión como la remoción de partículas.

La Figura 2 permite comparar de forma directa los meses invernales de mayor concentración con agosto, el mes más limpio dentro del conjunto de datos reportado.




Figura 2. Patrón estacional de PM2.5 en Culiacán: meses invernales frente al mes más limpio del año

La inversión térmica ofrece una explicación razonable para una parte del repunte invernal. Durante noches despejadas, el suelo pierde calor y enfría el aire cercano a la superficie, esa masa más densa puede quedar retenida bajo una capa relativamente cálida, con lo que disminuye la mezcla vertical. Las emisiones generadas a baja altura incluido el tránsito de las primeras horas del día permanecen entonces más tiempo en la zona de respiración y la concentración de PM2.5 puede aumentar (Mapasin, 2025).

Ese mecanismo combina precisamente variables que no actúan de manera aislada. Diferenciales térmicos, humedad y velocidad del viento interactúan y pueden producir umbrales o respuestas no lineales. Una red neuronal entrenada con datos históricos resulta adecuada para explorar esas relaciones sin imponer de antemano una forma funcional rígida.

2. Marco Normativo de la Calidad del Aire en México

Una predicción atmosférica adquiere valor operativo cuando puede interpretarse dentro de las reglas con las que se evalúa y comunica el riesgo. En México intervienen dos normas con funciones distintas: una fija criterios de concentración vinculados con la protección de la salud y otra establece la forma de informar el nivel de riesgo.

La NOM-025-SSA1-2021, emitida por la Secretaría de Salud (2021), fija los criterios de concentración recogidos en la Tabla 1: un límite anual de $10 \mu\text{g}/\text{m}^3$ y un promedio de 24 horas de $33 \mu\text{g}/\text{m}^3$ durante 2024-2025 que desciende a $25 \mu\text{g}/\text{m}^3$ desde 2026. La NOM-172-SEMARNAT-2023 regula, en cambio, cómo se comunica el riesgo asociado: organiza la condición atmosférica mediante el Índice aire y salud, con categorías de color y recomendaciones dirigidas a la población (SEMARNAT, 2023). Para el sistema propuesto, la consecuencia práctica es clara: el resultado numérico no debe quedarse como una cifra técnica, sino transformarse en un mensaje interpretable.

Para PM_{2.5}, la clasificación no depende de una lectura horaria aislada. La norma emplea un promedio móvil ponderado de 12 horas, asigna mayor peso a las observaciones recientes y exige una disponibilidad mínima de datos (SEMARNAT, 2023). Ese cálculo determina la categoría de riesgo; la Tabla 2 resume los intervalos que aplicaría el módulo de salida.

Rango de PM2.5 ($\mu\text{g}/\text{m}^3$)	Categoría	Nivel de riesgo	Recomendación a población sensible
0 a 12	Buena (verde)	Bajo	Actividades normales sin restricciones
Mayor que 12 y hasta 33	Aceptable (amarillo)	Moderado	Reducir actividades vigorosas al aire libre
Mayor que 33 y hasta 45	Mala (naranja)	Alto	Suspender la actividad si se presentan síntomas
Mayor que 45 y hasta 130	Muy mala (rojo)	Muy alto	Evitar por completo la actividad física exterior
Mayor que 130	Extremadamente mala (morado)	Extremadamente alto	Permanecer estrictamente en interiores

Tabla 2. Categorías del Índice aire y salud para PM2.5

3. Fundamentación Teórica de las Redes Neuronales Artificiales

El planteamiento predictivo parte del aprendizaje con datos históricos. En lugar de programar una a una las relaciones físico-químicas de la atmósfera, la red neuronal aproxima una función no lineal entre las variables de entrada y la concentración futura de PM2.5 (Goodfellow et al., 2016; LeCun et al., 2015). La física del fenómeno no se elimina, queda reflejada de manera indirecta en los patrones que el modelo logra aprender.

Las opciones disponibles implican compromisos diferentes. Los modelos físico-químicos de dispersión requieren inventarios de emisiones, condiciones de frontera y campos meteorológicos detallados, insumos que no siempre existen con la resolución necesaria a escala local. Una regresión lineal múltiple exige menos recursos, aunque puede quedarse corta ante interacciones no lineales o picos asociados con inversión térmica. Por esa razón se plantea un perceptrón multicapa (MLP) como línea base: ofrece flexibilidad sin exigir, desde el inicio, secuencias históricas tan extensas como otras arquitecturas. Si la cantidad y continuidad de los datos lo permiten, una etapa posterior podría contrastarlo con redes LSTM o con esquemas

híbridos, cuya memoria temporal ha resultado útil en series climáticas (Hochreiter y Schmidhuber, 1997; Prihatno et al., 2021).

El Perceptrón, el Perceptrón Multicapa y su Entrenamiento

El perceptrón constituye la unidad elemental de cálculo: multiplica cada entrada por un peso, incorpora un sesgo y transforma el resultado mediante una función de activación. Cuando esa activación es no lineal, por ejemplo ReLU o sigmoide, la unidad deja de comportarse como una combinación estrictamente lineal (Goodfellow et al., 2016).

Una sola unidad no basta para describir la dinámica atmosférica. Al organizar varios perceptrones en capas se obtiene un MLP: la capa de entrada recibe las variables ambientales, las capas ocultas construyen representaciones intermedias y la salida produce una estimación continua de PM2.5 para el horizonte definido. En esas representaciones pueden aparecer asociaciones que serían difíciles de modelar por separado, como la coincidencia entre presión elevada, viento débil y menor dispersión de partículas (LeCun et al., 2015).

Aprender significa ajustar los pesos de la red de forma iterativa. Al comienzo, esos parámetros no contienen relaciones útiles y las estimaciones suelen presentar errores altos. La retropropagación atribuye parte de ese error a cada conexión y proporciona la información necesaria para modificar los pesos en cada iteración (Rumelhart et al., 1986). Cada iteración recorre el mismo ciclo: un vector histórico atraviesa la red hasta producir una estimación, esa estimación se compara con la concentración medida por el sensor mediante una función de pérdida como el error cuadrático medio o el error absoluto medio, la regla de la cadena distribuye el error entre los pesos avanzando desde la salida hacia las capas anteriores y, con los gradientes disponibles, el optimizador actualiza los parámetros en la dirección que reduce la pérdida.

La estabilidad del entrenamiento depende de los hiperparámetros de optimización: una tasa de aprendizaje excesiva produce oscilaciones y una demasiado pequeña ralentiza la convergencia, por lo que se recurrirá a Adam, un optimizador con estimaciones adaptativas del gradiente de uso frecuente en series temporales (Kingma y Ba, 2017; Prihatno et al., 2021). Tras varias épocas de entrenamiento, la validación deberá comprobar si las regularidades aprendidas en los datos de Culiacán se mantienen fuera de la muestra utilizada para aprender.

Desafíos Críticos: Sobreajuste y Subajuste

Un error bajo en entrenamiento no garantiza un modelo útil: la red debe conservar su desempeño frente a datos que no observó durante el aprendizaje. Con capacidad insuficiente aparece subajuste y quedan sin representar patrones básicos, como la estacionalidad o los picos invernales; con capacidad excesiva para el volumen de datos disponible ocurre lo contrario, la red memoriza el ruido del sensor y pierde generalización. Dropout y detención temprana, esta última mediante el seguimiento del error en un conjunto de validación independiente, forman parte de las estrategias consideradas para controlar ese riesgo (Srivastava et al., 2014). La Tabla 3 contrasta ambos escenarios.

Criterio	Subajuste (underfitting)	Sobreajuste (overfitting)
Causa principal	Modelo con capacidad insuficiente o entrenamiento demasiado breve	Modelo con capacidad excesiva frente al volumen de datos disponible
Error de entrenamiento	Alto	Muy bajo
Error de validación	Alto y similar al de entrenamiento	Alto y creciente, muy superior al de entrenamiento
Comportamiento observado	No reproduce los picos invernales ni la estacionalidad	Reproduce el ruido del sensor y falla ante condiciones nuevas
Riesgo para el sistema de alerta	Alertas omitidas por subestimación sistemática	Falsas alarmas y pérdida de confianza pública
Estrategias de corrección	Añadir capas o neuronas, incorporar variables y prolongar el entrenamiento	Dropout, detención temprana, regularización y ampliación del conjunto de datos

Tabla 3. Subajuste y sobreajuste: causas, síntomas y soluciones

4. Propuesta de Solución: Sistema Predictivo

La propuesta integra cuatro componentes que conviene tratar como una sola cadena operativa: datos locales, preprocesamiento, modelado neuronal y comunicación normativa del resultado. La Figura 3 organiza ese flujo en cuatro fases.




Figura 3. Diagrama de flujo de las cuatro fases operativas del sistema predictivo propuesto

Fase 1: Extracción y Consolidación de Datos

La capacidad de pronóstico comienza con la calidad de la información disponible. La propuesta no añade hardware, aprovecha flujos existentes. La concentración objetivo se obtendría de repositorios o interfaces vinculadas con Redspira y Mapasin, redes que mantienen sensores activos en Culiacán (Redspira, s.f.; Revista Espejo, 2025). Las variables meteorológicas procederían de servicios con registros de temperatura, humedad relativa, presión y viento. A ello se sumarían atributos temporales codificados con seno y coseno para representar ciclos diarios, semanales y anuales sin discontinuidades artificiales. Esta codificación funciona como aproximación no mide el tráfico de forma directa, pero permite incorporar sus ritmos temporales probables. La Tabla 4 presenta el conjunto previsto de variables.

Variable	Tipo	Unidad o codificación	Fuente	Función en el modelo
Concentración de PM2.5	Dependiente y rezagada	$\mu\text{g}/\text{m}^3$	Redspira y Mapasin	Objetivo de predicción e historial reciente
Temperatura	Exógena continua	$^{\circ}\text{C}$	API meteorológica	Detección de inversión térmica
Humedad relativa	Exógena continua	%	API meteorológica	Modulación de la capacidad de la partícula para absorber humedad
Presión atmosférica	Exógena continua	hPa	API meteorológica	Indicador de estabilidad atmosférica
Velocidad del viento	Exógena continua	m/s	API meteorológica	Capacidad de dispersión del contaminante
Dirección del viento	Exógena cíclica	Seno y coseno del ángulo	API meteorológica	Origen probable de la masa de aire
Hora del día	Proxy temporal	Seno y coseno	Marca de tiempo	Representación del ciclo diario de tráfico
Día de la semana	Proxy temporal	Seno y coseno	Marca de tiempo	Distinción entre días laborales y de descanso
Mes del año	Proxy temporal	Seno y coseno	Marca de tiempo	Captura de la estacionalidad invernal

Tabla 4. Variables de entrada consideradas para el entrenamiento del modelo

Fase 2: Preprocesamiento de Datos

Las series generadas por sensores ambientales de bajo costo contienen imperfecciones. Ruido, interrupciones de comunicación y valores faltantes aparecen con cierta frecuencia, si esos defectos entraran sin tratamiento al entrenamiento, parte de ellos podría incorporarse al patrón aprendido. Por esa razón el preprocesamiento se concentra en dos tareas principales: imputación y escalamiento.

Los intervalos sin observaciones deben resolverse antes del entrenamiento, ya que la red no procesa de manera directa valores nulos. Cortes eléctricos, fallas de conectividad o mantenimiento pueden originar esos huecos. Se compararán interpolación temporal, medias móviles ponderadas y vecinos más cercanos, eligiendo el procedimiento según la duración de la ausencia y la estructura local de la serie. Hua et al. (2024) documentan que el método de imputación puede modificar de forma apreciable el desempeño de los modelos de calidad del aire, la elección, por tanto, debe validarse y no tratarse como un paso neutro.

El escalamiento resuelve un problema distinto: las variables operan en órdenes de magnitud muy diferentes. La presión atmosférica se sitúa alrededor de 1013 hPa, mientras que la concentración de PM2.5 ocupa un intervalo numérico mucho menor, esa disparidad puede afectar el descenso de gradiente. El proyecto aplicará MinMax para llevar cada variable a un rango común de 0 a 1, conservar su orden relativo y favorecer un entrenamiento numéricamente más estable (Goodfellow et al., 2016).

Fase 3: Arquitectura y Modelado

La línea base será un perceptrón multicapa implementado en Python con bibliotecas de cómputo tensorial. La entrada representará una ventana de 24 horas de las variables disponibles, después, varias capas densas con activación ReLU transformarán esa información. La salida generará una estimación para cada hora del horizonte de pronóstico. La Figura 4 resume la topología propuesta.




Figura 4. Arquitectura propuesta del perceptrón multicapa para el pronóstico de PM2.5

El MLP funcionará como referencia inicial, no como arquitectura definitiva. Si las series alcanzan longitud y continuidad suficientes, se comparará con una red LSTM o con un esquema híbrido. Las LSTM mantienen un estado interno y recurren a compuertas para decidir qué información conservar o descartar a lo largo de una secuencia, rasgo útil cuando el valor actual depende de condiciones ocurridas varias horas antes (Hochreiter y Schmidhuber, 1997; Prihatno et al., 2021). Una capa convolucional unidimensional previa podría extraer patrones locales entre variables antes del análisis temporal. La ventaja de esa alternativa, si aparece, deberá demostrarse empíricamente frente a la línea base.

La comparación utilizará tres métricas habituales: MAE, RMSE y R^2 . El MAE resume el error absoluto promedio, el RMSE penaliza con mayor fuerza las desviaciones grandes, R^2 expresa la proporción de variabilidad observada que logra explicar el modelo. Ninguna métrica

describe por sí sola todo el desempeño, de modo que se interpretarán de manera conjunta (Prihatno et al., 2021).

Fase 4: Despliegue y Generación de Alertas

Las predicciones deberán regresar a unidades físicas mediante el desescalamiento inverso. Una vez expresadas nuevamente en $\mu\text{g}/\text{m}^3$, un módulo posterior aplicará la metodología de la NOM-172-SEMARNAT-2023: calculará el promedio móvil ponderado de 12 horas proyectado y lo contrastará con los intervalos del Índice aire y salud (SEMARNAT, 2023). El resultado deja entonces de ser una salida matemática aislada y se convierte en una categoría de riesgo comprensible fuera del entorno técnico.

El pronóstico podría presentarse en un panel de alerta. Un escenario ilustrativo sería una condición roja prevista para la mañana siguiente por la combinación de inversión térmica y alta carga vehicular; el panel asociaría esa categoría con la recomendación sanitaria correspondiente. La herramienta no sustituiría la decisión de la autoridad. Su función sería aportar anticipación y contexto para decidir.

5. Análisis del Impacto Potencial de la Solución

El valor de una infraestructura predictiva no se agota en sus métricas estadísticas. También debe juzgarse por las decisiones que permite preparar durante las horas previas a un episodio de contaminación. En el contexto urbano de Sinaloa, el impacto potencial puede analizarse en tres frentes: salud pública, gestión institucional y desarrollo de capacidades técnicas locales.

1. Salud pública: una alerta con 24 horas de anticipación permitiría que escuelas, hospitales y centros geriátricos ajustaran actividades al aire libre cuando se prevean concentraciones elevadas. La medida no elimina la exposición, pero puede disminuirla en grupos

susceptibles; esa reducción resulta coherente con la evidencia sobre riesgos respiratorios asociados con PM2.5 (Becerra Pérez y Ramos Álvarez, 2020).

2. Gestión de contingencias: mientras el monitoreo oficial siga limitado, un pronóstico puede funcionar como señal temprana para priorizar inspecciones o valorar medidas temporales de control. Si el modelo anticipa un episodio relacionado con inversión térmica, las autoridades podrían revisar restricciones operativas sobre fuentes emisoras o reforzar la vigilancia de quemas a cielo abierto. Cualquier decisión de este tipo deberá mantenerse dentro de las atribuciones y protocolos institucionales vigentes.
3. Innovación local: entrenar y validar modelos con datos de Sinaloa puede fortalecer capacidades regionales en ciencia de datos aplicada y generar experiencia transferible a otras ciudades del estado. El aporte no consiste en sustituir la instrumentación ambiental, sino en medir hasta qué punto una capa analítica incrementa el valor preventivo de los datos que ya existen.

Agenda

La organización del trabajo restante se distribuye en ocho semanas, desde la consolidación de los datos hasta la redacción final del documento y la presentación de resultados.

La Tabla 5 resume las actividades previstas para cada semana y el entregable asociado.

Semana	Actividades	Entregable
1	- Investigación bibliográfica sobre PM2.5, redes neuronales artificiales (MLP y LSTM) y algoritmo de retropropagación. - Revisión del marco normativo (NOM-025-SSA1-2021 y NOM-172-SEMARNAT-2023). - Definición del alcance, objetivos y variables de entrada del modelo.	Protocolo de investigación y marco teórico
2	- Identificación de fuentes de datos abiertas (Redspira, Mapasin, API meteorológica). - Extracción y consolidación de registros históricos de PM2.5 y variables meteorológicas.	Dataset crudo consolidado
3	- Limpieza de las series de tiempo e imputación de valores faltantes (interpolación, medias móviles, vecinos más cercanos). - Codificación cíclica de las variables temporales.	Dataset preprocesado
4	- Escalamiento MinMax de las variables. - Construcción de ventanas temporales de 24 horas. - División en conjuntos de entrenamiento, validación y prueba.	Conjunto de datos listo para entrenamiento
5	- Implementación del perceptrón multicapa (MLP) en Python. - Entrenamiento inicial mediante retropropagación con el optimizador Adam. - Ajuste de hiperparámetros.	Modelo MLP entrenado (versión 1)
6	- Aplicación de dropout y detención temprana para controlar el sobreajuste. - Evaluación con las métricas MAE, RMSE y R². - Comparación exploratoria con una arquitectura LSTM.	Modelo optimizado y métricas de desempeño
7	- Implementación del módulo de traducción normativa (promedio móvil ponderado de 12 h e Índice aire y salud). - Diseño de un panel de alerta ilustrativo.	Módulo de clasificación de riesgo funcional
8	- Redacción del documento final y del análisis de impacto potencial. - Preparación de la presentación y diapositivas. - Ensayo de exposición.	Documento completo y presentación

Tabla 5. Cronograma de actividades del proyecto

Conclusiones

Culiacán reúne dos condiciones que justifican una atención sostenida: concentraciones de PM_{2.5} superiores a referencias sanitarias y una infraestructura oficial de monitoreo con interrupciones prolongadas (El Sol de Sinaloa, s.f.; Revista Espejo, 2024). Las redes ciudadanas de bajo costo han reducido una parte de ese vacío mediante observaciones locales más continuas (Redspira, s.f.). Esto conduce a una pregunta aplicada: si la información ya se genera, ¿puede aprovecharse para anticipar el riesgo en lugar de limitarse a describirlo después de que el episodio ocurrió?

La propuesta responde a esa pregunta mediante una arquitectura de redes neuronales: un perceptrón multicapa como línea base, por su capacidad para aproximar relaciones no lineales, y redes LSTM como alternativa posterior, condicionada a que la longitud y continuidad de las series justifiquen un tratamiento explícitamente secuencial. El diseño no se agota en el modelo: antes del entrenamiento las series requieren limpieza, imputación y escalamiento, y después la salida debe recuperar sus unidades físicas para traducirse al Índice aire y salud. Esa conexión entre ingeniería de datos, modelado y normativa ambiental constituye uno de los elementos centrales de la propuesta (Goodfellow et al., 2016; SEMARNAT, 2023).

La ruta planteada ofrece una forma razonable de transformar observaciones dispersas en información anticipada, aunque la validación empírica sigue pendiente. Una etapa posterior deberá entrenar el modelo con series completas, comparar arquitecturas bajo un mismo protocolo de evaluación, incorporar fuentes adicionales, por ejemplo, profundidad óptica de aerosoles obtenida por satélite y contrastar los pronósticos con mediciones independientes. Solo entonces podrá estimarse con precisión la utilidad operativa del sistema más allá del ejercicio académico.

Referencias

- Becerra Pérez, L. A., y Ramos Álvarez, R. A. (2020). Evaluación del impacto en la salud por partículas PM2.5 en Sinaloa, México. *Revista Internacional de Contaminación Ambiental*, 36(2), 249-259. <https://doi.org/10.20937/RICA.53463>
- El Sol de Sinaloa. (s.f.). *Sinaloa lleva una década sin estaciones activas para medir la calidad del aire*. <https://oem.com.mx/elsoldesinaloa/local/sinaloa-lleva-una-decada-sin-estaciones-activas-para-medir-la-calidad-del-aire-31044479>
- Goodfellow, I., Bengio, Y., y Courville, A. (2016). *Deep learning*. MIT Press.
- Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Hua, V., Nguyen, T., Dao, M.-S., Nguyen, H. D., y Nguyen, B. T. (2024). The impact of data imputation on air quality prediction problem. *PLOS ONE*, 19(9), e0306303. <https://doi.org/10.1371/journal.pone.0306303>
- Kingma, D. P., y Ba, J. (2017). *Adam: A method for stochastic optimization*. arXiv. <https://arxiv.org/abs/1412.6980>
- LeCun, Y., Bengio, Y., y Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444. <https://doi.org/10.1038/nature14539>
- Mapasin. (2025). *Reporte anual de calidad del aire en Culiacán 2025*. <https://mapasin.org/blog/Reporte-anual-de-calidad-del-aire-en-Culiacan-2025>
- Organización Mundial de la Salud. (2021). *Directrices mundiales de la OMS sobre la calidad del aire: partículas (PM2.5 y PM10), ozono, dióxido de nitrógeno, dióxido de azufre y monóxido de carbono*. <https://www.who.int/publications/i/item/9789240034228>

- Prihatno, A. T., Nurcahyanto, H., Ahmed, M. F., Rahman, M. H., Alam, M. M., y Jang, Y. M. (2021). Forecasting PM2.5 concentration using a single-dense layer BiLSTM method. *Electronics*, 10(15), 1808. <https://doi.org/10.3390/electronics10151808>
- Redspira. (s.f.). *Mapa de calidad del aire*. <http://www.redspira.org/>
- Revista Espejo. (2024, 11 de marzo). *El aire que respiramos en Sinaloa: omisiones en supervisión*. <https://revistaespejo.com/2024/03/11/el-aire-que-respiramos-en-sinaloa-omisiones-en-supervision/>
- Revista Espejo. (2025, 30 de enero). *CIIDIR Sinaloa medirá la calidad del aire en principales ciudades de Sinaloa*. <https://revistaespejo.com/2025/01/30/ciidir-sinaloa-medira-la-calidad-del-aire-en-principales-ciudades-de-sinaloa/>
- Rumelhart, D. E., Hinton, G. E., y Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536. <https://doi.org/10.1038/323533a0>
- Secretaría de Medio Ambiente y Recursos Naturales. (2023). *Norma Oficial Mexicana NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comunicación del Índice de Calidad del Aire y Riesgos a la Salud*. Diario Oficial de la Federación. <https://dof.gob.mx/normasOficiales/9393/semarnat/semarnat.html>
- Secretaría de Salud. (2021). *Norma Oficial Mexicana NOM-025-SSA1-2021, Salud ambiental. Criterios para evaluar la calidad del aire ambiente con respecto a las partículas suspendidas PM10 y PM2.5*. Diario Oficial de la Federación.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., y Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56), 1929-1958.